

Aprendizaje Automático II - Trabajo Práctico 1

Redes neuronales feed forward y convolucionales

TUIA - FCEIA, UNR

Grupo: 5

Integrantes	Legajo
Facundo Molina	M-7128/5
Martín Facundo Lapolla	L-3372/3
Jonatan Gallardo	G-5970/6
Gabriel Soda	S-5679/1

Introducción y criterio de trabajo

El trabajo aplica redes neuronales a problemas de clasificación y regresión. Este informe resume el procedimiento, las decisiones, los desafíos y los aprendizajes. El código, los gráficos y el detalle de los experimentos se encuentran en los notebooks de cada ejercicio.

En los dos primeros ejercicios usamos la semilla 42. Separamos entrenamiento, validación y test. Train ajusta los pesos, validación permite elegir las configuraciones y test se reserva para evaluar el modelo seleccionado. Los transformadores que aprenden valores de los datos se ajustan solo con train.

1. Clasificación binaria de ACV

1.1. Procedimiento y datos

Trabajamos con 5.110 pacientes. La variable objetivo es `stroke`. Hay 249 positivos (4,87 %) y 4.861 negativos (95,13 %). No se encontraron filas completas ni identificadores duplicados. Los únicos faltantes fueron 201 valores de BMI (3,93 %).

Exploramos las variables con histogramas, boxplots, correlaciones y proporciones por categoría. Edad presentó la mayor correlación de Spearman con `stroke` entre las variables examinadas (0,25). Glucosa y BMI mostraron valores extremos y solapamiento entre clases. Conservamos esos extremos para no eliminar posibles casos relevantes. Estas asociaciones no prueban causalidad.

Eliminamos `id` y dividimos de forma estratificada en 3.066 pacientes para train, 1.022 para validación y 1.022 para test. Validación y test tienen 50 positivos cada uno.

1.2. Decisiones y justificación

Completamos BMI con la mediana de train por intervalos de edad de 20 años y género. La mediana global de train funciona como respaldo. Elegimos medianas porque los valores extremos influyen menos que sobre la media. La agrupación permite incorporar diferencias entre grupos, aunque no se probó que supere otras imputaciones.

Usamos One-Hot para categorías y variables binarias, sin asignarles un orden artificial. Dejamos una categoría de referencia con `drop="first"`. Conservamos `Unknown` en tabaquismo porque es una categoría explícita. Estandarizamos edad, glucosa y BMI con `StandardScaler`. El resultado tiene 16 entradas.

El MLP de referencia tiene arquitectura 16-64-1 y 1.153 parámetros. Usa ReLU y dropout de 0,3 en la capa oculta. La salida entrega un logit y la pérdida es `BCEWithLogitsLoss`. Aplicamos sigmoid al evaluar para obtener scores entre 0 y 1.

Entrenamos con Adam, tasa 0,001, `weight_decay=0,0001` y batches de 64. Permitimos hasta 500 épocas, con paciencia 30 y mejora mínima de pérdida de validación de 0,0001. Restauramos los mejores pesos para limitar el sobreajuste.

1.3. Experimentos y resultados

Las curvas y la evaluación en test se muestran en el Anexo A.

Comparamos BorderlineSMOTE, aplicado solo a train, con la ponderación de positivos en la pérdida. BorderlineSMOTE llevó ambas clases a 2.917 registros. La ponderación mantuvo los pacientes originales y usó `pos_weight=2917/149`, aproximadamente 19,58. También comparamos tres arquitecturas con ponderación.

Arquitectura	Parámetros	F2 en validación	Recall en validación
16-64-1	1.153	0,4366	84 %
16-32-1	577	0,4343	82 %
16-64-32-1	3.201	0,4310	80 %

Elegimos 16-64-1 por su mayor F2. Las diferencias fueron pequeñas y corresponden a una sola semilla. El modelo de 32 neuronas sigue siendo una alternativa razonable por su menor tamaño.

Seleccionamos los umbrales con F2 en validación. Esta métrica da más importancia a recall que F1, porque buscamos reducir los falsos negativos. Con el umbral elegido para cada método, `pos_weight` obtuvo F2 de 0,4366 frente a 0,3779 de BorderlineSMOTE. Detectó 42 positivos frente a 39 y generó 239 falsos positivos frente a 277.

La configuración final fue el modelo ponderado, con pesos de la época 16 y umbral 0,567368. El entrenamiento se detuvo en la época 46. La pérdida de train seguía bajando cuando validación dejó de mejorar, lo que respaldó recuperar un checkpoint anterior. Las pérdidas ponderadas no se comparan directamente con las de BCE sin ponderar.

Métrica de test	Resultado	Métrica de test	Resultado
Accuracy	75,64 %	Precisión	14,34 %
Recall	80,00 %	F1	0,2432
F2	0,4175	AUC-ROC	0,8487
Especificidad	75,41 %	Precisión promedio (AP)	0,3151

La matriz de test contiene 733 verdaderos negativos, 239 falsos positivos, 10 falsos negativos y 40 verdaderos positivos. Una predicción siempre negativa tendría 95,11 % de accuracy, pero no detectaría ningún positivo. Por eso accuracy sola resulta engañosa en este problema.

1.4. Desafíos, limitaciones y aprendizajes

El principal desafío fue detectar positivos sin producir demasiadas falsas alertas. Detectamos 40 de 50 casos, pero 239 de las 279 alertas fueron incorrectas. Los 10 falsos negativos podrían quedar sin señalar si se usara el resultado para descartar una revisión. El modelo no fue validado para tomar decisiones clínicas.

Aprendimos que tratar el desbalance y elegir el umbral son decisiones distintas. F2 permitió explicitar la prioridad de recall, pero no impuso una precisión mínima aceptable. Las limitaciones principales son los pocos positivos, una sola partición y varias decisiones sobre la misma validación. BorderlineSMOTE también puede producir indicadores categóricos fraccionarios tras One-Hot. Como mejoras proponemos repetir particiones, comparar una regresión logística ponderada y probar imputaciones o sobremuestreo adecuados para datos mixtos.

2. Clasificación multiclase de dígitos

2.1. Procedimiento y datos

Usamos MNIST, con imágenes de dígitos del 0 al 9 en escala de grises y tamaño 28×28 . Leímos los cuatro archivos IDX y verificamos encabezados, cantidades, dimensiones y etiquetas. Dividimos las 60.000 imágenes originales de train en 48.000 para entrenamiento y 12.000 para validación mediante estratificación. Conservamos las 10.000 imágenes oficiales de test.

Mostramos una grilla de imágenes, las frecuencias de cada dígito y los histogramas de intensidad. Las clases de train representan entre 9,04 % y 11,24 % del total. Consideramos el conjunto aproximadamente balanceado y no aplicamos sobremuestreo. En los histogramas predominan los píxeles negros del fondo.

2.2. Decisiones y justificación

Aplanamos cada imagen en 784 valores y convertimos los píxeles a float32. Dividimos por 255 para llevarlos a $[0, 1]$. Esta transformación fija conserva el orden y las frecuencias de las intensidades. Usamos intervalos equivalentes en ambos histogramas para comparar correctamente el antes y el después.

Mantenemos las etiquetas como enteros de 0 a 9 y las convertimos a `torch.long`. CrossEntropyLoss acepta esos índices, por lo que no hace falta usar one-hot. El modelo entrega logits y no aplica softmax antes de la pérdida. Softmax se usa para analizar la confianza.

Componente	Configuración y motivo
Arquitectura	784-128-64-10, con 109.386 parámetros. Dos capas ocultas para combinar patrones con un tamaño moderado.
Activaciones	ReLU en las capas ocultas para aprender relaciones no lineales. Salida lineal con diez logits.
Regularización	Dropout de 0,3 y decaimiento de pesos de 0,0001 para limitar el sobreajuste.
Optimización	AdamW con tasa inicial de 0,001 y batches de 64.
Tasa de aprendizaje	ReduceLROnPlateau, factor 0,5 y paciencia 2, según pérdida de validación.
Selección de pesos	Hasta 30 épocas y early stopping tras 7 épocas sin nueva pérdida mínima de validación.

Al terminar cada época medimos train y validación con pesos fijos y dropout desactivado. También conservamos las métricas obtenidas durante las actualizaciones. Así distinguimos el proceso de optimización de la comparación entre conjuntos.

2.3. Entrenamiento y sobreajuste

El Anexo B reúne las curvas, la matriz y los ejemplos de errores.

La menor pérdida de validación se obtuvo en la época 18 (0,0793). El entrenamiento se detuvo en la 25 y recuperamos esos pesos. Entre las épocas 18 y 25, la pérdida de train en evaluación bajó de 0,0143 a 0,0082. La de validación osciló y terminó en 0,0834.

En la última época, train en evaluación alcanzó aproximadamente 99,8 % de accuracy frente a 98,0 % de validación. Esta diferencia muestra sobreajuste, aunque no hubo una caída sostenida fuerte de accuracy de validación. El cruce con la curva de train durante las actualizaciones no basta para identificar su inicio, porque esa curva incluye dropout activo.

2.4. Resultados y análisis de errores

El checkpoint seleccionado obtuvo 97,94 % de accuracy y pérdida 0,0756 en test. Acertó 9.794 imágenes y falló en 206. Accuracy es un resumen adecuado por el balance aproximado de las clases, pero la complementamos con resultados por dígito y la matriz de confusión.

Dígito	Aciertos por clase	Dígito	Aciertos por clase
0	99,08 %	5	97,76 %
1	99,12 %	6	98,23 %
2	97,97 %	7	97,57 %
3	98,22 %	8	96,61 %
4	98,17 %	9	96,53 %

Los aciertos por clase se calculan sobre los ejemplos reales de cada dígito, por lo que corresponden a su recall. Las confusiones más frecuentes fueron 9 hacia 4 (13), 7 hacia 2 (8), 4 hacia 9 (7) y 7 hacia 9 (7). Agrupando ambas direcciones, 4 y 9 acumularon 20 errores. Los lazos abiertos o cerrados y los trazos diagonales ofrecen posibles explicaciones visuales.

Analizamos los cinco errores de mayor confianza, mostrados en el notebook. Sus índices de test son 3520, 1681, 2654, 4601 y 5331. Corresponden a 6 hacia 4, 3 hacia 7, 6 hacia 1, 8 hacia 4 y 1 hacia 6. Todos superaron 99,95 % de confianza softmax. Algunos tienen trazos ambiguos, pero el último no ofrece una semejanza clara con un 6. Estas observaciones no prueban qué características usó el modelo ni que las etiquetas estén mal.

2.5. Desafíos, limitaciones y aprendizajes

Los desafíos fueron reconocer distintas formas de escritura y comparar correctamente las curvas. Medir train y validación sin dropout permitió observar una brecha que era menos evidente con las métricas tomadas durante las actualizaciones.

El MLP conserva los píxeles al aplanar, pero debe aprender las relaciones entre sus posiciones. Una CNN podría aprovechar filtros locales y compartirlos en distintas partes de la imagen para detectar bordes, curvas y uniones. No se implementó una CNN en este ejercicio ni se demostró que mejore el resultado.

Aprendimos que una buena accuracy no garantiza confianza fiable. El resultado tampoco asegura rendimiento sobre fotos, fondos distintos o varios dígitos en una imagen. Como mejoras futuras proponemos comparar arquitecturas y pequeñas transformaciones solo sobre train, cuidando que no cambien la identidad del dígito.

3. Regresión de ganancias

4. Clasificación de razas con CNN

Fuentes del desarrollo

Consigna: TP 1 - Redes Feed Forward y Convolucionales.pdf. Resultados: AA2_tp1_problema1.ipynb y AA2_tp1_problema2.ipynb. Las cifras corresponden a las ejecuciones guardadas en esos notebooks.

Anexo A. Imágenes del ejercicio 1

Gráficos extraídos de las salidas guardadas de AA2_tp1_problema1.ipynb.




Imagen 1. Modelo con pos_weight. La línea marca los pesos elegidos en la época 16. Train y validación se miden sin dropout. El recall de estas curvas usa umbral 0,5 y no el umbral final elegido por F2.




Imagen 2. Evaluación en test con el umbral fijado en validación. La matriz muestra 40 positivos detectados, 10 omitidos y 239 falsas alertas. Las curvas ROC y precisión-recall resumen los scores sin elegir un nuevo umbral con test.

Anexo B. Imágenes del ejercicio 2

Imágenes extraídas de las salidas guardadas de AA2_tp1_problema2.ipynb.




Imagen 3. Curvas de pérdida, accuracy y tasa de aprendizaje. Train en evaluación y validación usan los mismos pesos al terminar cada época y no tienen dropout activo. La línea discontinua registra train durante las actualizaciones.





Imagen 4. Matriz de confusión de test. Las filas indican el dígito real y las columnas la predicción. Las confusiones entre 4 y 9 suman 20 errores.

Muestras Incorrectas con Mayor Confianza


Índice: 3520 | Real: 6
Pred: 4 (99.999%)



Índice: 1681 | Real: 3
Pred: 7 (99.984%)



Índice: 2654 | Real: 6
Pred: 1 (99.983%)



Índice: 4601 | Real: 8
Pred: 4 (99.956%)



Índice: 5331 | Real: 1
Pred: 6 (99.954%)




Imagen 5. Cinco errores con mayor confianza softmax. Los índices permiten identificar las imágenes. Todos superan 99,95 % de confianza, aunque sus predicciones no coinciden con las etiquetas del dataset.